

## 1 Introduction:


En matière d'apprentissage automatique, la machine de Boltzmann restreinte (RBM) représente un type de réseau de neurones artificiels destiné à l'apprentissage non supervisé. Son utilisation fréquente réside dans l'estimation de la distribution probabiliste d'un ensemble de données. Dans le cadre de ce travail pratique, nous allons mettre en œuvre une classe RBM afin de tester ce modèle sur divers ensembles de données. Nous procéderons à une analyse des résultats en tenant compte des hyperparamètres et de l'erreur de reconstruction.

## 2 Description des bases de données:


Trois Bases de données ont été utilisées pour ce TP:

- Binary Alphadigits
- MNIST
- USPS


**Binary Alphadigits:** Ce jeu de données est téléchargeable du lien: <http://www.cs.nyu.edu/~roweis/data.html>. Il contient des images binaires de tailles  $20 \times 16$  représentant les caractères de 0 à 9 et de A à Z.



**MNIST:** Ce jeu de données contient des images 8-bits en nuance de gris de tailles  $28 \times 28$  représentant les caractères de 0 à 9.




**USPS:** Ce jeu de données contient des images 8-bits en nuance de gris de tailles  $16 \times 16$  représentant les caractères de 0 à 9.



### 3 Architecture de RBM:

La construction d'un RBM (Restricted Boltzmann Machine) se fait à partir de la classe RBM munie des fonctions : `entree_sortie_RBM`, `sortie_entree_RBM` et `train_RBM`



- a : biais des unités d'entrée
- b : biais des unités de sortie
- W : la matrice représentant les poids de notre réseau reliant les variables visibles aux variables cachées.
- p : dimension de a
- q : dimension de b

**Pour mieux comprendre le code du projet**, on détaillera ci-dessous le rôle de chaque méthode et fonction utilisée :

- `entree_sortie_RBM(RBM,V)` renvoie  $\sigma(V \times W + b)$  avec  $\sigma(x) = \frac{1}{1+e^{-x}}$ .
- `sortie_entree_RBM(RBM,H)` renvoie  $\sigma(H \times W + a)$  avec  $\sigma(x) = \frac{1}{1+e^{-x}}$ .
- `train_RBM(X, nb_iter, lr, batch_size)` entraîne le RBM avec les données X.
- `lire_alpha_digits(caracteres)` permet de lire les données de la base de donnée Binary Alpha Digits. En fait, `lire_alpha_digits` récupère les données des caractères choisis et les applatit. Elle transforme alors chaque échantillon de taille  $20 \times 16$  en un tableau de taille  $1 \times 320$ .
- `generer_image_RBM(RBM, iter_gibbs, nb_img)` est la fonction responsable de la génération d'images à partir d'un RBM par un échantillonneur de Gibbs


## 4 Evaluation des performances en fonction des hyperparamètres:

### 4.1 Influence du nombre d'unités cachées:

Le tableau suivant représente les performances du modèle RBM sur la dataset Binary Alphanum Digits en fonction du nombre d'unités cachées. On constate que l'erreur de reconstruction diminue lorsque le nombre d'unités

cachées augmente.

Nombre d'unités cachées	100	200	300	500	1000
Erreur de reconstruction	0.150	0.012	0.004	0.001	0.0002



(a) RBM avec 100 unités cachées



(b) RBM avec 200 unités cachées



(c) RBM avec 300 unités cachées



(d) RBM avec 500 unités cachées




(e) RBM avec 1000 unités cachées

On remarque qu'en augmentant le nombre d'unités cachées, on améliore la qualité de la génération. Ceci est dû au fait qu'on complexifie le modèle pour lui permettre de capturer certains détails dans la data. Cependant, il faut aussi le contrôler pour éviter la Overfit qui pourrait inciter le modèle à recopier la input en output.

## 4.2 Influence du nombre de caractères à apprendre:

Le tableau suivant représente les performances du modèle RBM sur la dataset Binary Alphanum digits en fonction du nombre de caractères à apprendre. On constate que l'erreur de reconstruction augmente lorsque le nombre de caractères à apprendre augmente. (Ce test est fait en utilisant un RBM avec 200 unités cachées)


Nombre de caractères à apprendre	1	2	3	5	10
Erreur de reconstruction	0.007	0.010	0.012	0.014	0.0235



(a) RBM avec 1 caractère à apprendre




(b) RBM avec 2 caractères à apprendre



(c) RBM avec 3 caractères à apprendre



(d) RBM avec 5 caractères à apprendre



(e) RBM avec 10 caractères à apprendre

On remarque qu'en augmentant le nombre de caractères à apprendre, on diminue la qualité de la génération. Ceci signifie que le modèle peut avoir des difficultés à capturer les caractéristiques distinctives de chaque caractère et à les reproduire avec précision. La solution pourrait être de complexifier davantage le modèle et donc d'ajouter des unités cachées.

## **5 Evaluation du modèle sur le dataset MNIST et USPS:**

On va comparer le modèle sur les ensembles de chiffres entre 0 et 9 et on ne considère pas les caractères de l'alphabet qui sont uniquement présents sur la base de données Binary Alphanum.

### **5.1 Evaluation sur MNIST:**

### **5.2 Evaluation sur USPS:**